Introducción a los Chatbots

Chatbots y LLMs

Objetivo de la clase. Que el alumno comprenda los fundamentos para trabajar con chatbots basados en LLMs, entienda las diferencias con los bots basados en reglas y conozca las principales características para empezar a trabajar con modelos de IA.

Chatbots: definición y evolución

Un chatbot es un **programa informático que mantiene una conversación** con una persona en **lenguaje natural**, ya sea por texto o por voz, y responde de manera automática. Su trabajo consiste en recibir un mensaje, interpretar la necesidad del usuario y, a partir de ello, elegir o generar una respuesta.

La idea de conversar con una máquina tiene una larga historia. En 1950, Alan Turing planteó el **Test de Turing**, que reemplaza la pregunta "¿pueden pensar las máquinas?" por una medible: ¿pueden conversar como una persona? Si una persona dialoga por texto con una máquina y con otra persona y no logra distinguir cuál es la máquina, la máquina supera la prueba.

En 1966 apareció ELIZA, el primer chatbot conocido, que funcionaba por reglas. En 1995 se lanzó A.L.I.C.E., un chatbot por reglas más sofisticado, basado en patrones. Entre 2011 y 2014 llegaron los asistentes de voz Siri, Google Now y Alexa, y en 2022 el lanzamiento de ChatGPT marcó la aparición de los LLMs (Grandes Modelos de Lenguaje).

El test de Turing fue **superado en 2025 por el modelo ChatGPT de OpenAI**: un 73% de los entrevistados eligió al LLM como humano en lugar de a la persona real, cuando ningún intento previo había superado el 50%.

Tipos de chatbots y modelos

Existen dos tipos de chatbots. Los **basados en reglas** responden siguiendo instrucciones escritas de antemano por una persona: reconocen palabras clave y solo pueden responder aquello para lo que fueron programados. Los **basados en LLMs** generan cada respuesta en el momento a partir de un modelo de IA entrenado: interpretan lo que se les escribe y construyen una respuesta nueva en lugar de elegir una guardada.

Es importante distinguir entre chatbot y modelo. Todos los chatbots basados en LLMs trabajan con un modelo por detrás, pero **no son el modelo en sí, sino herramientas basadas en él**: a partir de un mismo modelo se generan distintas herramientas, y el chatbot

es solo una de ellas. Existen numerosos modelos (OpenAI, Grok, Gemini, DeepSeek, Claude, entre otros), y una misma empresa posee varios, cada uno especializado en distintas funcionalidades:

Modelo / Familia	Propósito Principal
GPT-4o / Claude 3.5 Sonnet	**Razonamiento general y texto:** generación de contenido, redacción avanzada, análisis de datos y programación.
Midjourney / Flux / DALL-E 3	**Generación visual:** imágenes artísticas, fotorrealismo y diseño gráfico a partir de texto.
Whisper / ElevenLabs	**Procesamiento de audio:** transcripción de voz a texto y síntesis de voz hiperrealista.
Sora / Runway Gen-3	**Generación de video:** creación y edición de secuencias de video mediante instrucciones escritas.

El prompt y su optimización

Un prompt es la consulta del usuario: el **mensaje o instrucción que se le escribe** al chatbot. Como la respuesta depende de él, un mismo problema puede dar respuestas distintas según cómo se lo plantee. Para evitar ambigüedades, conviene estructurarlo en cuatro elementos:

- **Objetivo:** define con claridad qué se espera obtener; una tarea concreta evita respuestas vagas.
- **Contexto y rol:** aporta la información de fondo (situación, público, datos relevantes) y asigna a la IA un perfil desde el cual responder.
- **Restricciones:** establece los límites de la respuesta, como extensión, tono o elementos a incluir y a evitar.
- **Formato:** indica cómo debe presentarse el resultado: tabla, lista, párrafos, esquema o código.

La diferencia se observa en un ejemplo. Un mal prompt sería: "Escribile un mail al cliente para decirle que la entrega del proyecto se va a demorar una semana". Un buen prompt asigna un rol (Project Manager experimentado), aporta el contexto (reprogramación del hito final del 10 al 17 de octubre por ajustes de control de calidad), define el objetivo (mantener la confianza del cliente), fija restricciones (máximo 150 palabras, sin disculpas excesivas ni tecnicismos) y especifica el formato (asunto, saludo, motivo principal, tres beneficios en viñetas y cierre con un llamado a la acción).

Además, hay técnicas que mejoran los resultados: **dar ejemplos** de lo esperado, **dividir la tarea en partes**, **pedir que se expliciten los supuestos**, **solicitar el razonamiento paso a paso** y **pedir que la IA haga preguntas** antes de responder.

Tokens

Un token es la **unidad básica de texto** que un modelo de IA procesa y comprende. A partir de tokens, la IA descompone la información para analizarla y generar respuestas. Este sistema permite procesar palabras nuevas sin necesidad de un diccionario infinito, reutilizar prefijos y sufijos para ahorrar memoria, trabajar con código, múltiples idiomas y símbolos con el mismo mecanismo, y comprender el texto aun con errores tipográficos o de ortografía.

Cada solicitud consume tokens de un límite diario o semanal, según el proveedor. Optimizar las solicitudes permite gestionarlos mejor y aprovecharlos al máximo.

Chats y contexto

Dentro de la aplicación de un chatbot, el usuario puede tener distintos chats, lo que permite guardar el contexto de los temas hablados previamente e iterar sobre una respuesta sin reescribir la solicitud desde cero. El **contexto** es todo lo que el modelo tiene a la vista para responder: el mensaje actual, la conversación previa y los archivos adjuntos.

Conviene cuidar el chat. Cada modelo tiene un límite de tokens por consulta y, superado ese límite, las respuestas se vuelven más ineficientes y aumenta el consumo de tokens. Además, un mensaje enviado no se puede eliminar del contexto, por lo que es crucial evitar contradicciones que confundan al modelo. Cuando el contexto está sobrecargado, lo mejor es cambiar de chat: resumir la conversación y copiarla en uno nuevo ayuda a evitar alucinaciones y a mejorar los resultados.

Errores de la IA

Los modelos de IA dan sus respuestas en base a datos y probabilidades. Si los datos son insuficientes o de mala calidad, pueden cometer errores. Los dos principales son:

- **Alucinación:** respuesta incorrecta o inventada que el chatbot presenta con aparente seguridad. Puede generar texto verosímil sin fundamentos, por lo que es vital verificar toda la información brindada.
- **Sesgo:** tendencia sistemática del modelo a favorecer ciertos resultados, perspectivas o grupos sobre otros de forma injusta o distorsionada; por ejemplo, asociar ciertas profesiones con un género o representar mejor una cultura o idioma que otros.